

Segmentação de Estradas com DeepLabV3+ no Dataset KITTI Road: Impacto da Resolução de Entrada

Sara Souza Rodrigues

Curso de Análise e Desenvolvimento de Sistemas – Instituto Federal de Educação, Ciência e Tecnologia do Piauí (IFPI), Campus Corrente
Corrente – PI – Brasil

Abstract. *This paper presents an evaluation of the DeepLabV3+ architecture with a ResNet-50 backbone applied to road segmentation using the KITTI Road Segmentation dataset. Two experiments were conducted to assess the impact of input image resolution — 256x256 and 512x512 pixels — on segmentation quality and computational cost. Models were trained for 10 epochs using Dice Loss and the Adam optimizer, and evaluated using IoU, Precision, Recall and F1-Score. Results show that the 512x512 configuration achieved a higher IoU (0.9426) and F1-Score (0.9700) than the 256x256 configuration (IoU 0.9232, F1-Score 0.9595), at the cost of a smaller batch size and greater memory demand, indicating a trade-off between segmentation accuracy and computational efficiency that is relevant to embedded autonomous driving systems.*

Resumo. *Este artigo apresenta uma avaliação da arquitetura DeepLabV3+ com backbone ResNet-50 aplicada à segmentação de estradas utilizando o dataset KITTI Road Segmentation. Foram conduzidos dois experimentos para avaliar o impacto da resolução das imagens de entrada — 256x256 e 512x512 pixels — na qualidade da segmentação e no custo computacional. Os modelos foram treinados por 10 épocas utilizando Dice Loss e o otimizador Adam, sendo avaliados pelas métricas IoU, Precisão, Recall e F1-Score. Os resultados mostram que a configuração 512x512 obteve IoU (0,9426) e F1-Score (0,9700) superiores à configuração 256x256 (IoU 0,9232, F1-Score 0,9595), ao custo de um tamanho de lote (batch) menor e maior demanda de memória, evidenciando um trade-off entre acurácia de segmentação e eficiência computacional relevante para sistemas embarcados de condução autônoma.*

1. Introdução

O avanço no desenvolvimento de sistemas de transporte inteligentes e de veículos autônomos tem impulsionado a necessidade de algoritmos de percepção visual computacional altamente precisos e robustos. Entre as tarefas mais críticas para a navegação autônoma segura está a identificação em tempo real do espaço navegável, comumente tratada na literatura como segmentação de estradas. A detecção precisa dos limites asfálticos e das pistas de rolagem permite que o sistema de controle veicular planeje trajetórias, evite colisões e execute manobras operacionais com segurança.

Apesar dos progressos recentes, a segmentação de cenas urbanas e rodoviárias enfrenta desafios severos no ambiente real. Fatores como variações abruptas de iluminação (sombras de árvores, reflexos solares), diferentes tipos de pavimentação, presença de oclusões (veículos e pedestres) e desgaste das marcações viárias impõem barreiras complexas para os algoritmos tradicionais de processamento de imagens. Nesse cenário, as Redes Neurais Convolucionais (CNNs) profundas consolidaram-se como o estado da arte para extração de características semânticas complexas.

Este trabalho aborda especificamente a segmentação de regiões navegáveis utilizando a arquitetura de vanguarda DeepLabV3+ aplicada sobre o renomado dataset KITTI Road Segmentation. O objetivo geral deste estudo é analisar o desempenho e a robustez do modelo na

identificação pixel a pixel de vias de trânsito. Como objetivo específico e investigação experimental, avalia-se o impacto direto da resolução espacial das imagens de entrada no processo de treinamento e na qualidade das máscaras preditas, contrastando as resoluções de 256x256 pixels e 512x512 pixels.

A justificativa para este estudo reside na busca pelo equilíbrio ideal entre o custo computacional (tempo de processamento e uso de memória) e a acurácia das métricas de segmentação, um fator decisivo para a viabilização de sistemas embarcados em tempo real dentro de automóveis autônomos. Este artigo está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica; a Seção 3 detalha os materiais e métodos empregados; a Seção 4 expõe e discute os resultados obtidos; e a Seção 5 finaliza com as conclusões e propostas de trabalhos futuros.

2. Fundamentação Teórica

2.1 Redes Neurais Convolucionais e Segmentação Semântica

As Redes Neurais Convolucionais (CNNs) revolucionaram a visão computacional ao automatizar o processo de extração de características hierárquicas das imagens, eliminando a necessidade de engenharia de features manual. Enquanto redes convolucionais voltadas para classificação reduzem a resolução espacial para emitir um único rótulo global, as tarefas de segmentação semântica exigem uma predição densa, ou seja, a classificação individual de cada pixel pertencente à imagem de entrada.

Para alcançar esse mapeamento de densidade pixel a pixel, as arquiteturas modernas comumente utilizam estruturas baseadas em redes totalmente convolucionais (FCNs) organizadas em formato de codificador-decodificador (encoder-decoder). O codificador atua na redução progressiva da resolução espacial para extrair conceitos semânticos de alto nível. Em contrapartida, o decodificador reconstrói a resolução espacial original por meio de técnicas de upsampling, permitindo o alinhamento preciso das máscaras geradas com as bordas reais dos objetos da cena.

2.2 A Arquitetura DeepLabV3+

O DeepLabV3+, proposto por Chen et al. (2018), representa uma evolução marcante na segmentação semântica ao combinar as vantagens das estruturas de decodificadores com mecanismos baseados em Convoluções Dilatadas (Atrous Convolutions). O grande diferencial do DeepLabV3+ reside na sua capacidade de controlar explicitamente a resolução das características extraídas pela rede neural sem a necessidade de adicionar parâmetros treináveis.

A convolução dilatada introduz um fator de taxa de dilatação (r) que expande o campo receptivo do filtro convolucional, inserindo lacunas (espaçamentos nulos) entre os pesos do núcleo convolucional. Matematicamente, para um sinal unidimensional $x[i]$ e um filtro $w[k]$ de tamanho K , a convolução dilatada é definida por:

$$y[i] = \sum_{k=1..K} x[i + r \cdot k] \cdot w[k]$$

Essa operação permite que o modelo capture contextos de larga escala e informações globais da estrada (como a curvatura da via no horizonte) sem perder a resolução espacial que penalizaria a precisão das bordas próximas ao veículo. Adicionalmente, a arquitetura incorpora o módulo Atrous Spatial Pyramid Pooling (ASPP), que aplica em paralelo múltiplos filtros convolucionais dilatados, cada um operando com uma taxa de amostragem distinta ($r = 1, 6$ e 12). Essa amostragem piramidal permite robustez na extração de feições em múltiplas escalas simultaneamente, tratando de forma eficaz objetos que mudam de tamanho conforme a proximidade da câmera do veículo.

Por fim, o módulo decodificador do DeepLabV3+ melhora significativamente a recuperação de detalhes finos ao concatenar as características de alto nível vindas do ASPP (após um

upsampling bilinear) com características de baixo nível vindas diretamente das camadas iniciais do codificador. Essa fusão preserva informações espaciais cruciais para o delineamento nítido das margens viárias.

2.3 O Backbone ResNet-50

Embora a especificação original do DeepLabV3+ faça uso do Xception, neste trabalho foi adotada a ResNet-50 como rede dorsal (backbone) de extração de características, por meio da biblioteca segmentation-models-pytorch. A arquitetura ResNet introduziu o conceito de conexões de salto (skip connections ou blocos residuais), que permitem o fluxo direto do gradiente de erro através das camadas.

Essa abordagem atenua o problema do desvanecimento do gradiente (vanishing gradient), comum em redes muito profundas, facilitando a convergência durante a otimização e permitindo que o DeepLabV3+ se beneficie de pesos pré-treinados no banco de dados ImageNet por meio de Aprendizado por Transferência (Transfer Learning).

2.4 Métricas de Avaliação em Segmentação

O desempenho dos modelos de segmentação de estradas foi mensurado quantitativamente por métricas baseadas em pixels classificados como Verdadeiro Positivo (TP), Falso Positivo (FP), Falso Negativo (FN) e Verdadeiro Negativo (TN):

$$IoU = TP / (TP + FP + FN)$$

$$Precisão = TP / (TP + FP)$$

$$Recall = TP / (TP + FN)$$

$$F1 = 2 \cdot Precisão \cdot Recall / (Precisão + Recall)$$

3. Materiais e Métodos

3.1 Base de Dados

Foi utilizado o dataset KITTI Road Segmentation (Fritsch, Kuehnl e Geiger, 2013), benchmark público amplamente empregado em pesquisas de percepção veicular. A base disponibiliza imagens RGB de cenas urbanas e rodoviárias reais (diretório image_2), acompanhadas de suas respectivas máscaras de segmentação binária (diretório gt_image_2), nas quais os pixels pertencentes à via navegável são codificados por um padrão de cor específico.

Para a construção das máscaras binárias utilizadas no treinamento, os pixels de estrada foram identificados a partir de um limiar sobre os canais de cor da máscara original ($R > 100$ e $B > 100$), convertendo cada máscara em uma matriz binária onde 1 representa via navegável e 0 representa fundo.

3.2 Pré-processamento e Divisão dos Dados

O conjunto de dados foi dividido em 80% para treinamento, 10% para validação e 10% para teste, utilizando amostragem aleatória com semente fixa (random_state = 42) para garantir a reprodutibilidade dos experimentos. As imagens e máscaras foram redimensionadas para a resolução de cada experimento (256x256 ou 512x512), convertidas para o espaço de cor RGB e normalizadas para o intervalo [0, 1].

3.3 Arquitetura e Configuração do Treinamento

Dois experimentos foram conduzidos para isolar o efeito da resolução de entrada:

- Experimento 1: imagens redimensionadas para 256x256 pixels, com batch size de 4 amostras;
- Experimento 2: imagens redimensionadas para 512x512 pixels, com batch size de 2 amostras (reduzido em função do maior consumo de memória da GPU).

Em ambos os experimentos, o modelo utilizado foi o DeepLabV3+ com encoder ResNet-50 pré-treinado no ImageNet, treinado por 10 épocas com a função de perda Dice Loss e o otimizador Adam, com taxa de aprendizado fixa de $1e-4$. A métrica de IoU foi monitorada na base de validação ao final de cada época para acompanhar a convergência do modelo.

3.4 Ambiente Experimental e Avaliação

O treinamento foi realizado em ambiente Google Colab, utilizando uma GPU Nvidia T4, com as bibliotecas PyTorch e segmentation-models-pytorch. Após o treinamento, os dois modelos foram avaliados na base de teste (não vista durante o treino ou a validação), calculando-se as métricas de IoU, Precisão, Recall e F1-Score para cada resolução.

4. Resultados e Discussão

A Figura 1 apresenta a evolução da perda de treino (Dice Loss) e do IoU de validação ao longo das 10 épocas para os dois experimentos. É possível observar que o Experimento 2 (512x512) apresentou uma queda de perda mais acentuada nas primeiras épocas e atingiu valores de IoU de validação consistentemente mais altos a partir da metade do treinamento, embora ambos os modelos tenham convergido de forma estável, sem sinais evidentes de overfitting no intervalo avaliado.




Figura 1. Curva de perda de treino e evolução do IoU de validação — Experimento 1 (256x256) e Experimento 2 (512x512).

Os resultados finais na base de teste, não utilizada durante o treinamento ou a validação, são apresentados na Tabela 1.

Tabela 1. Comparativo de métricas na base de teste.

Métrica	Exp. 1 (256x256)	Exp. 2 (512x512)
IoU	0,9232	0,9426
Precisão	0,9454	0,9726
Recall	0,9750	0,9684
F1-Score	0,9595	0,9700

Os resultados confirmam que o aumento da resolução de entrada de 256x256 para 512x512 pixels produziu ganhos consistentes em praticamente todas as métricas de segmentação: o IoU aumentou de 0,9232 para 0,9426, a Precisão de 0,9454 para 0,9726 e o F1-Score de 0,9595 para 0,9700. A única métrica em que o Experimento 1 superou o Experimento 2 foi o Recall (0,9750 contra 0,9684), sugerindo que o modelo treinado em menor resolução tende a superestimar levemente a área de via navegável, capturando mais pixels de estrada às custas de um número maior de falsos positivos — refletido em sua Precisão inferior.




Figura 2. Exemplo qualitativo de segmentação (Experimento 2, 512x512): imagem original, gabarito real e máscara predita.

A Figura 2 ilustra qualitativamente esse comportamento, comparando a imagem original de uma cena de teste, o gabarito real (máscara) e a segmentação predita pelo modelo do Experimento 2. A região central da via foi corretamente identificada, com contornos que acompanham de forma consistente os limites reais da pista, mesmo diante de elementos de oclusão presentes na cena, como o veículo e a vegetação lateral.

Do ponto de vista de custo computacional, o ganho de desempenho do Experimento 2 não é gratuito: a resolução mais alta exigiu a redução do batch size de 4 para 2 amostras devido à limitação de memória da GPU, além de implicar em maior tempo de processamento por época e maior custo de inferência. Esse resultado evidencia o trade-off central investigado neste trabalho — entre acurácia de segmentação e eficiência computacional — um fator determinante para a viabilidade de embarcar o modelo em sistemas veiculares de tempo real, nos quais restrições de hardware e latência são tão relevantes quanto a acurácia do modelo.

5. Conclusão e Trabalhos Futuros

Este trabalho avaliou o desempenho da arquitetura DeepLabV3+ com backbone ResNet-50 na tarefa de segmentação de estradas sobre o dataset KITTI Road, investigando especificamente o impacto da resolução de entrada — 256x256 e 512x512 pixels — na qualidade da segmentação e no custo computacional do treinamento.

Os resultados demonstraram que a resolução de 512x512 pixels proporcionou ganhos consistentes de IoU, Precisão e F1-Score em relação à resolução de 256x256, ao custo de um batch size menor e maior demanda computacional. Já a resolução de 256x256 obteve o maior Recall, sendo uma alternativa viável em cenários com restrição de hardware, onde o custo computacional é um fator mais crítico do que a precisão máxima de segmentação.

Como trabalhos futuros, sugere-se a avaliação de resoluções intermediárias e superiores a 512x512, o uso de técnicas de data augmentation para aumentar a robustez do modelo a variações de iluminação e oclusão, a comparação com o backbone Xception original da proposta do DeepLabV3+, e a medição do tempo de inferência por imagem em hardware embarcado, de forma a complementar a análise de acurácia com uma análise de viabilidade em tempo real.

6. Referências

- Chen, L., Zhu, Y., Papandreou, G., Schroff, F. and Adam, H. (2018) "Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation", In: European Conference on Computer Vision (ECCV).
- Fritsch, J., Kuehnl, T. and Geiger, A. (2013) "A New Performance Measure and Evaluation Benchmark for Road Detection Algorithms", In: IEEE International Conference on Intelligent Transportation Systems (ITSC).
- He, K., Zhang, X., Ren, S. and Sun, J. (2016) "Deep Residual Learning for Image Recognition", In: IEEE Conference on Computer Vision and Pattern Recognition (CVPR).

- Kingma, D. P. and Ba, J. L. (2015) "Adam: A Method for Stochastic Optimization", In: International Conference on Learning Representations (ICLR).
- Milletari, F., Navab, N. and Ahmadi, S. (2016) "V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation", In: International Conference on 3D Vision (3DV).
- Yakubovskiy, P. (2019) "Segmentation Models Pytorch", In: GitHub repository, https://github.com/qubvel/segmentation_models.pytorch